

# **Deteccção de Misoginia Multiclasse em Redes Sociais com Modelos de Linguagem**

Adrielle Marques

- **Objetivo:** Desenvolver classificador de misoginia para redes sociais com detecção de nuances específicas.
- **Diferencial:** Superação do ódio genérico via categorização detalhada (Assédio, Descrédito, Ameaça, Misoginia Geral).
- **Metodologia:** Fine-tuning comparativo de 4 modelos da família BERT.

# Fine-tuning

- Processo de adaptar um modelo de linguagem pré-treinado para uma tarefa específica.
- Aproveita o conhecimento adquirido durante o pré-treinamento e ajusta seus parâmetros com um novo conjunto de dados.
- Permite que o modelo aprenda padrões específicos do domínio, sem precisar ser treinado do zero.

# Datasets

## MINA-BR



Exatas  
(Universidade Estadual de Campinas)

Repositório de Dados de Pesquisa da Unicamp > Exatas >

### MINA-BR: base de dados para identificação de discurso de ódio contra a mulher na internet

Version 1.0

Plath, Hannah de Oliveira; de Oliveira Paiva, Maria Estela; Pinto, Danielle Lanza; Costa, Paula Dornhofer Pato, 2025, "MINA-BR: base de dados para identificação de discurso de ódio contra a mulher na internet", <https://doi.org/10.25824/redu/MQD68Z>, Repositório de Dados de Pesquisa da Unicamp, V1, UNF:6:HNhm1hWbnOGfjliAcYGA== [fileUNF]

[Cite Dataset](#) [Learn about Data Citation Standards](#)

**Description**

A base MINA-BR é composta de três datasets principais. O dataset "MINA-BR" consiste num conjunto de comentários retirados da Internet em português do Brasil, com foco específico em textos direcionados a mulheres. O dataset "MINA-BR Rotulada" contém uma parcela dos comentários do dataset "MINA-BR" rotulados por três anotadores distintos, resultando em comentários classificados como ÓDIO (1) ou NÃO ÓDIO (0). Os comentários também foram rotulados como OFENSIVOS (1) ou NÃO OFENSIVOS (0). Finalmente, o dataset "MINA-BR Anotadores" contém informações sobre o perfil dos rotuladores. (2021-08-01)

**Subject**

Computer and Information Science; Social Sciences

**Keyword**

Processamento de Linguagem Natural (NLP), Aprendizado de máquina, Discurso de ódio, Misoginia

**Related Publication**

Plath, Hannah O., et al. "Detecção de Discurso de Ódio Contra Mulheres em Textos em Português Brasileiro: Construção da Base MINA-BR e Modelo de Classificação." Revista Eletrônica de Iniciação Científica em Computação 20.3 (2022).

**License/Data Use Agreement** [Custom Dataset Terms](#)

**Access Dataset**

Contact Owner Share

**Dataset Metrics**

394 Downloads

- Classificação: Ódio (1) Não ódio (0).
- Transformação dos dados rotulados como Ódio(1) em multilabel:
  - Descrédito Intelectual.
  - Assédio Sexual.
  - Ameaça Física.
  - Misoginia Geral
  - Não-Misógino.

# Datasets

## Deepseek API - Dados sintéticos

- Dados sintéticos.
- Aproximadamente dois mil dados.
- Multilabel:
  - Descrédito Intelectual.
  - Assédio Sexual.
  - Ameaça Física.
  - Misoginia Geral
  - Não-Misógino.



# Modelos

- **BERTomelo** - unb-labia/BERTomelo-ModernBERT-Large-v1
- **BERTimbau** - neuralmind/bert-large-portuguese-cased
- **RoBERTa** - FacebookAI/xlm-roberta-base
- **BERT** - google-bert/bert-large-uncased



# Métricas

- **Matriz de Confusão**

- A Matriz de Confusão cruza valores reais vs. valores previstos pelo modelo.
- Identifica onde o modelo falha (quais classes ele confunde).

- **F1- Score**

- F1-Score mede a qualidade das previsões finais do modelo. Ele considera tanto quantas previsões positivas estavam corretas quanto quantos exemplos positivos realmente foram encontrados.
- $F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ 
  - 0 → pior desempenho
  - 1 → melhor desempenho

# Avaliação dos Modelos: Métricas de Fine-Tuning


| Modelo           | F1       |
|------------------|----------|
| BERTomelo-Large  | 0.907255 |
| BERTimbau-Large  | 0.895141 |
| BERT-Large       | 0.849301 |
| xlm-roberta-base | 0.821379 |



# Matriz de Confusão

## BERTomelo-Large


|                        | precision | recall | f1-score | support |
|------------------------|-----------|--------|----------|---------|
| Ameaça Física          | 0.83      | 0.97   | 0.89     | 65      |
| Assédio Sexual         | 0.94      | 0.94   | 0.94     | 86      |
| Descrédito Intelectual | 0.91      | 0.95   | 0.93     | 64      |
| Misoginia Geral        | 0.76      | 0.78   | 0.77     | 143     |
| Não-Misógino           | 0.92      | 0.88   | 0.90     | 402     |
| accuracy               |           |        | 0.88     | 760     |
| macro avg              | 0.87      | 0.90   | 0.89     | 760     |
| weighted avg           | 0.88      | 0.88   | 0.88     | 760     |



# Matriz de Confusão

## BERTimbau-Large


|                        | precision | recall | f1-score | support |
|------------------------|-----------|--------|----------|---------|
| Ameaça Física          | 0.92      | 0.91   | 0.91     | 65      |
| Assédio Sexual         | 0.96      | 0.93   | 0.95     | 86      |
| Descrédito Intelectual | 0.94      | 0.95   | 0.95     | 64      |
| Misoginia Geral        | 0.76      | 0.79   | 0.77     | 143     |
| Não-Misógino           | 0.92      | 0.91   | 0.91     | 402     |
| accuracy               |           |        | 0.89     | 760     |
| macro avg              | 0.90      | 0.90   | 0.90     | 760     |
| weighted avg           | 0.89      | 0.89   | 0.89     | 760     |



# Matriz de Confusão

## XMLRoBERTa-base


|                        | precision | recall | f1-score | support |
|------------------------|-----------|--------|----------|---------|
| Ameaça Física          | 0.81      | 0.88   | 0.84     | 65      |
| Assédio Sexual         | 0.90      | 0.88   | 0.89     | 86      |
| Descrédito Intelectual | 0.81      | 0.91   | 0.85     | 64      |
| Misoginia Geral        | 0.58      | 0.71   | 0.64     | 143     |
| Não-Misógino           | 0.89      | 0.79   | 0.84     | 402     |
| accuracy               |           |        | 0.80     | 760     |
| macro avg              | 0.80      | 0.83   | 0.81     | 760     |
| weighted avg           | 0.82      | 0.80   | 0.81     | 760     |



# Matriz de Confusão

## BERT-Large

|                        | precision | recall | f1-score | support |
|------------------------|-----------|--------|----------|---------|
| Ameaça Física          | 0.92      | 0.85   | 0.88     | 65      |
| Assédio Sexual         | 0.80      | 0.90   | 0.85     | 86      |
| Descrédito Intelectual | 0.76      | 0.89   | 0.82     | 64      |
| Misoginia Geral        | 0.58      | 0.76   | 0.66     | 143     |
| Não-Misógino           | 0.91      | 0.77   | 0.83     | 402     |
| accuracy               |           |        | 0.80     | 760     |
| macro avg              | 0.79      | 0.83   | 0.81     | 760     |
| weighted avg           | 0.82      | 0.80   | 0.80     | 760     |



# Tabela Comparativa de Desempenho dos 4 Modelos

| Posição | Modelo                      | F1-Score (Macro) | F1 por Classe (Menor → Maior)                                                                                                                                                                        | Análise da Matriz de Confusão                                                                                                                                                                 | Principais Destaques                                                                                                |
|---------|-----------------------------|------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------|
| 1º      | BERTimbau-Large (Português) | 0.90             | <ul style="list-style-type: none"> <li>Misoginia Geral: 0.77</li> <li>Ameaça Física: 0.91</li> <li>Não-Misógino: 0.91</li> <li>Assédio Sexual: 0.95</li> <li>Descrédito Intelectual: 0.95</li> </ul> | Excelente equilíbrio. A classe mais desafiadora ("Misoginia Geral") tem F1 de 0.77, enquanto as demais classes têm F1 acima de 0.91. A matriz mostra uma diagonal muito forte e poucos erros. | <b>MELHOR DESEMPENHO GERAL.</b> Especialista em português, com excelente capacidade de distinguir todas as classes. |
| 2º      | BERTomelo-ModernBERT-Large  | 0.89             | <ul style="list-style-type: none"> <li>Misoginia Geral: 0.77</li> <li>Ameaça Física: 0.89</li> <li>Não-Misógino: 0.90</li> <li>Assédio Sexual: 0.94</li> <li>Descrédito Intelectual: 0.93</li> </ul> | Muito equilibrada. Desempenho muito similar ao BERTimbau, com ligeira inferioridade em "Ameaça Física" (0.89 vs 0.91) e "Descrédito Intelectual" (0.93 vs 0.95).                              | Excelente modelo, mas com desempenho ligeiramente inferior ao BERTimbau nas classes mais críticas.                  |
| 3º      | XLM-RoBERTa (Multilíngue)   | 0.81             | <ul style="list-style-type: none"> <li>Misoginia Geral: 0.64</li> <li>Ameaça Física: 0.84</li> <li>Não-Misógino: 0.84</li> <li>Assédio Sexual: 0.89</li> <li>Descrédito Intelectual: 0.85</li> </ul> | Desempenho mediano. A classe "Misoginia Geral" tem F1 de apenas 0.64, indicando dificuldade em distingui-la das demais. Mais erros de classificação entre classes similares.                  | Sofre por ser multilíngue e não ter foco no português.                                                              |
| 4º      | BERT-Large (Inglês)         | 0.81             | <ul style="list-style-type: none"> <li>Misoginia Geral: 0.66</li> <li>Ameaça Física: 0.88</li> <li>Não-Misógino: 0.83</li> <li>Assédio Sexual: 0.85</li> <li>Descrédito Intelectual: 0.82</li> </ul> | Desempenho mediano. Similar ao XLM-RoBERTa, mas com ligeira piora em "Não-Misógino" (0.83 vs 0.84) e "Assédio Sexual" (0.85 vs 0.89).                                                         | Limitado pela falta de conhecimento do idioma português.                                                            |

# Infência

## BERTimbau-Large

Texto: Lugar de mulher é na cozinha, ela não entende nada de política.  
Resultado: Misoginia Geral (74.03%)

Texto: Você é muito burra para discutir esse assunto de economia.  
Resultado: Descrédito Intelectual (88.39%)

Texto: Vou te pegar na saída da faculdade e você vai ver o que te espera.  
Resultado: Ameaça Física (98.67%)

## BERTomelo-Large

Texto: Lugar de mulher é na cozinha, ela não entende nada de política.  
Resultado: Descrédito Intelectual (44.51%)

Texto: Você é muito burra para discutir esse assunto de economia.  
Resultado: Descrédito Intelectual (56.86%)

Texto: Vou te pegar na saída da faculdade e você vai ver o que te espera.  
Resultado: Ameaça Física (95.75%)

## xml-RoBERTa-Base

Texto: Lugar de mulher é na cozinha, ela não entende nada de política.  
Resultado: Misoginia Geral (82.72%)

Texto: Você é muito burra para discutir esse assunto de economia.  
Resultado: Descrédito Intelectual (79.76%)

Texto: Vou te pegar na saída da faculdade e você vai ver o que te espera.  
Resultado: Ameaça Física (92.37%)

## BERT-Large

Texto: Lugar de mulher é na cozinha, ela não entende nada de política.  
Resultado: Misoginia Geral (69.20%)

Texto: Você é muito burra para discutir esse assunto de economia.  
Resultado: Descrédito Intelectual (80.13%)

Texto: Vou te pegar na saída da faculdade e você vai ver o que te espera.  
Resultado: Ameaça Física (98.38%)



# Interaja com o modelo:

**Classificador de misoginia  
multiclasse**

Built with Streamlit

Fullscreen



# Conclusão

- Superioridade dos Modelos Nativos: Modelos treinados em português (BERTimbau e BERTomelo) superam modelos multilíngues na captura de nuances do nosso idioma.
- O Desafio da "Misoginia Geral": A classe mais subjetiva apresentou a maior dificuldade (menor F1-Score) para todos os modelos, evidenciando a complexidade do discurso de ódio.
- Viabilidade Multiclasse: A transição de uma detecção binária (ódio/não ódio) para uma categorização detalhada provou-se altamente eficaz (F1 geral ~0.90).
- Trabalhos Futuros: Refinamento e balanceamento da base de dados, com aprimoramento da classe Misoginia Geral e evolução para classificação multi-label, permitindo identificar múltiplas categorias de misoginia em uma mesma mensagem e representando de forma mais fiel a complexidade dos discursos de ódio.